BIG DATA

PROYECTO FINAL

Josué Juan Hormiga Benítez

New Technology School

Tokio.

New
Technology
School



Josué Juan Hormiga Benítez

RESPONSABLE DEL DESARROLLO DEL PROYECTO

Fecha: 15, febrero, 2026

BIG DATA
PROYECTO FINAL
Josué Juan Hormiga Benítez

Tokio.

Abstract

This Master's Thesis will address the analysis of large-scale datasets within the context of Big Data, a field that has become increasingly relevant due to the exponential growth of information generated by digital systems, connected devices, and online platforms. The main objective is to apply a robust, real-world case study to the understanding and processing of massive datasets, exploring their technological foundations, analytical methodologies, and practical applications. To this end, we will divide the thesis into chapters, where we will develop and apply the knowledge acquired during the master's program to solve a real-world problem.

We will address concepts such as exploratory analysis, data cleaning, data completeness, machine learning (ML) model prediction, and model accuracy or reliability. By analyzing these concepts using specific techniques once we have structured the data, we will be able to draw conclusions that will help us extract actionable information, optimize decision-making processes, and identify patterns that would otherwise remain hidden within the large volumes of information provided.

Resumen

Este Trabajo de Fin de Máster (TFM) abordará el análisis de conjuntos de datos a gran escala en el contexto del Big Data, un campo que ha cobrado cada vez mayor relevancia debido al crecimiento exponencial de la información generada por sistemas digitales, dispositivos conectados y plataformas en línea. El objetivo principal es aplicar un caso práctico sólido real para la comprensión y el procesamiento de datos masivos, explorando sus fundamentos tecnológicos, metodologías analíticas y aplicaciones prácticas. Para ello, dividiremos el TFM en capítulos, donde iremos desarrollando y aplicando los conocimientos obtenidos durante el máster para poder resolver un problema de un escenario real.

Abordaremos conceptos como el análisis exploratorio, limpieza de datos, completitud de los datos, predicción de modelos de machine learning (ML) y veracidad o fiabilidad del modelo. Analizando mediante técnicas concretas estos conceptos una vez hayamos estructurado los datos, podremos extraer conclusiones que nos ayudarán a extraer información procesable, optimizar los procesos de toma de decisiones e identificar patrones que de otra manera permanecerían ocultos entre los grandes volúmenes de información proporcionada.

Agradecimientos

La culminación de este Trabajo de Fin de Máster representa el mayor logro de mi trayectoria académica hasta la actualidad, y no hubiera sido posible sin el apoyo incondicional de personas extraordinarias que han estado conmigo en todo momento dando su apoyo para poder seguir adelante.

En primer lugar, quiero expresar mi más profundo agradecimiento a mi madre, cuyo amor y sacrificio ha sido el pilar fundamental de mi vida. Su dedicación y esfuerzo constante me ha inspirado a perseguir mis sueños con pasión, dedicación y trabajo incesante. Tanto así, que cuando ni yo mismo creía que fuera posible, ella sí lo creyó. Gracias a ella adquirí mi saber estar, educación, caballerosidad y ambición, además de muchas otras que, si me pusiera a relatar, no vería el momento de acabar.

A mi abuela, cuya presencia permanente y ayuda silenciosa ha sido una fuente constante de respaldo y motivación. Su ejemplo de vida me ha enseñado el valor de la resiliencia y la importancia de seguir adelante a pesar de los fracasos, a pesar de que creas que todo va mal. De ella aprendí que a veces, cuando todo va mal, solo hay que tirar del carro y seguir adelante aun cuando todo parezca derrumbarse.

A mi novia, cuyo amor y comprensión han sido mi refugio en los momentos de mayor desafío durante los últimos dos años. Su apoyo incondicional y su capacidad para ver lo mejor de mí me han impulsado a superar mis límites y alcanzar mis metas, mientras que un abrazo suyo silenciaba todo el ruido. Gracias a ella alcancé la calma y aprendí a ver el mundo de una forma distinta.

Finalmente, quiero expresar mi gratitud a todas aquellas personas que, de una u otra forma, han contribuido a la realización de este trabajo. Su apoyo y aliento han sido fundamentales para alcanzar este logro.

Índice General

1. Clasificación de datos mediante la plantilla.
2. Consultas con Cassandra.
3. Análisis exploratorio con PySpark.
4. Análisis descriptivo con PySpark.
5. Análisis de correlación.
6. Selección de algoritmo predictivo.
7. Explicación de la toma del algoritmo.
8. Conclusión.

I. Clasificación de datos mediante la plantilla.

El primer paso para desarrollar y solucionar un problema de Big Data es entender el tipo de datos que vamos a manejar, por tanto, debemos clasificarlos para entender los tipos que vamos a manejar y como deberemos tratarlos más adelante. Para eso usaremos la plantilla que se nos ha propuesto:

Nombre del campo	Tipo de dato
CustomerID	Texto
Age	Flotante
Gender	Texto
Tenure	Flotante
Usage Frequency	Flotante
Support Calls	Flotante
Payment Delay	Flotante
Subscription Type	Texto
Contract Length	Texto
Total Spend	Flotante
Last Interation	Flotante
Churn_YesNo	Texto

Todos los datos son de tipo float (es decir, tipo numérico) excepto *CustomerID*, *Gender*, *Subscription_Type*, *Contract_Lenght*, y *Churn_YesNo* que son de tipo string (tipo texto). Más adelante, de ser necesario para incorporar las variables a nuestro modelo (salvo *CustomerID*, que se nos indica explícitamente que no puede ser usado en modelos de aprendizaje y que lo tratemos como texto) podremos hacer una transformación a tipo numérico y añadirlas a nuestro modelo.

Los datos que tenemos representan lo siguiente:

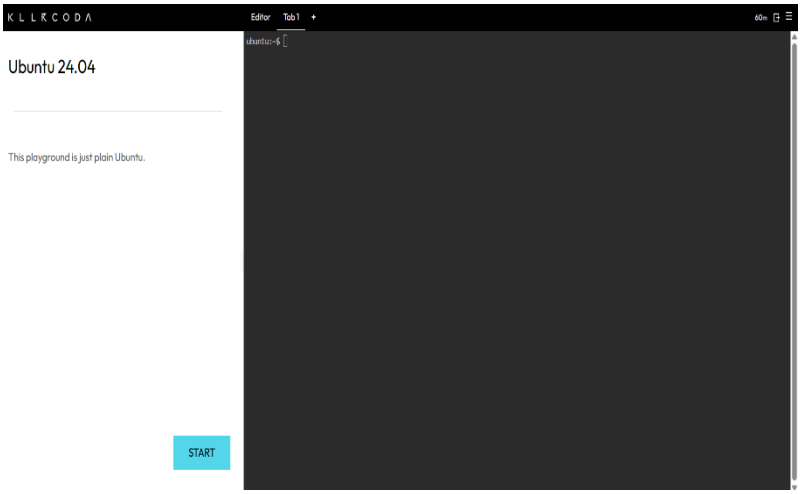
1. *CustomerID*: Es un identificativo interno que nos permite localizar a un cliente sin posibles conflictos.
2. *Age*: Nos indica la edad del cliente.
3. *Gender*: Nos indica el género del cliente.
4. *Tenure*: antigüedad del cliente
5. *Usage Frequency*: frecuencia de uso del teléfono
6. *Support Calls*: es el número de llamadas al servicio de atención al cliente

7. *Payment Delay*: es el número de retrasos en el pago
8. *Subscription Type*: nos indica el tipo de tarifa
9. *Contract Lenght*: es la duración del contrato
10. *Total Spend*: es el gasto total
11. *Last Iteration*: dias desde la última interacción con el cliente
12. *Churn_ YesNo*: Nos indica si el cliente ha dado de baja el servicio (en tal caso será -> Yes).

II. Consultas con Cassandra

Lo primero de todo para empezar esta tarea es tener nociones básicas para poder acceder a la interfaz, cargar los datos y empezar a hacer consultas. Vamos a ir paso a paso:

- Acceder al enlace: https://killercoda.com/playgrounds/scenario/ubuntu
- Nos aparecerá la siguiente ventana, donde pulsaremos start y tendremos 60 minutos para trabajar:



- Una vez que pulsamos start debemos ejecutar los siguientes comandos en el orden que vamos a indicar:
  1. ***Descargamos la imagen de Cassandra***: docker pull cassandra:3.11
  2. ***Creamos la red***: docker network create cassandra
  3. ***Iniciamos el contenedor***: docker run –rm -d –name cassandra –hostname cassandra –network cassandra cassandra:3.11
  4. ***Conectamos con cqlsh***: docker run –rm -it –network cassandra nuvo/Docker-cqlsh cqlsh cassandra 9042 –cqlversion='3.4.4'

Ahora empezamos a trabajar con los datos y hacemos las consultas que se nos indica (encontraremos todo el código en los archivos adjuntos).

El procedimiento que se ha seguido para obtener los resultados es el siguiente:

1. Creamos la base de datos llamada *customer_ churn* donde cada dato se almacena en un único nodo del cluster.
2. Nos metemos en la base de datos.
3. Eliminamos cualquier posible tabla existente con el nombre que vamos a querer utilizar por si ha quedado algún registro de las pruebas anteriores.

4. Creamos una tabla con cada tipo previamente definido y la nombramos como *customers.*
5. Salimos de la base de datos.
6. Importamos los datos del CSV a al contenedor que hemos creado de Cassandra.
7. Nos metemos en la base de datos y copiamos los datos que hemos importado dentro de nuestra tabla que habíamos definido previamente con los campos y los tipos adecuadamente.
8. Creamos unos índices que nos permitan recorrer los datos en las consultas posteriores paras las columnas *subscription_type* y *contract_lenght.*
9. Hacemos la consulta de conteo de clientes con el tipo de subscripción *Basic*.
10. Hacemos la consulta de conteo de clientes con el tipo de subscripción *Basic* y longitud de contrato *Annual.*
11. Salimos y guardamos el registro de comandos en un .txt para añadir al entregable.

Tras hacer todas las consultas llegamos a la conclusión de que tenemos **3233** suscripciones **básicas**, y **1250** suscripciones **básicas anuales**.

Podremos verificar paso a paso todos los comandos utilizados para llegar a estas conclusiones en el documento técnico, sin embargo, los comandos que nos han permitido la resolución de estos dos problemas son:

- `SELECT COUNT(*) FROM customers WHERE subscription_type = 'Basic';`
- `SELECT COUNT(*) FROM customers WHERE subscription_type = 'Basic' AND contract_length = 'Annual' ALLOW FILTERING;`

Con esos dos comandos, una vez cargados los datos en Cassandra y copiados en la tabla que previamente hemos creado, nos permite obtener la información que necesitamos.

Con la información recopilada anteriormente se puede crear un plan de negocios para mejorar las condiciones, ya sean del propio producto o bien para poder llegar a recaudar más de dichos clientes. Por ejemplo, con los dos datos que poseemos podemos concluir que aproximadamente solo un tercio de las suscripciones básicas son clientes que están fidelizados durante 1 año asegurado. Podríamos pensar en alternativas para fidelizar dos tercios o el total de la clientela durante un mayor tiempo. También se podrían implementar estrategias para que los clientes fidelizados durante 1 año abonaran otro tipo de servicios.

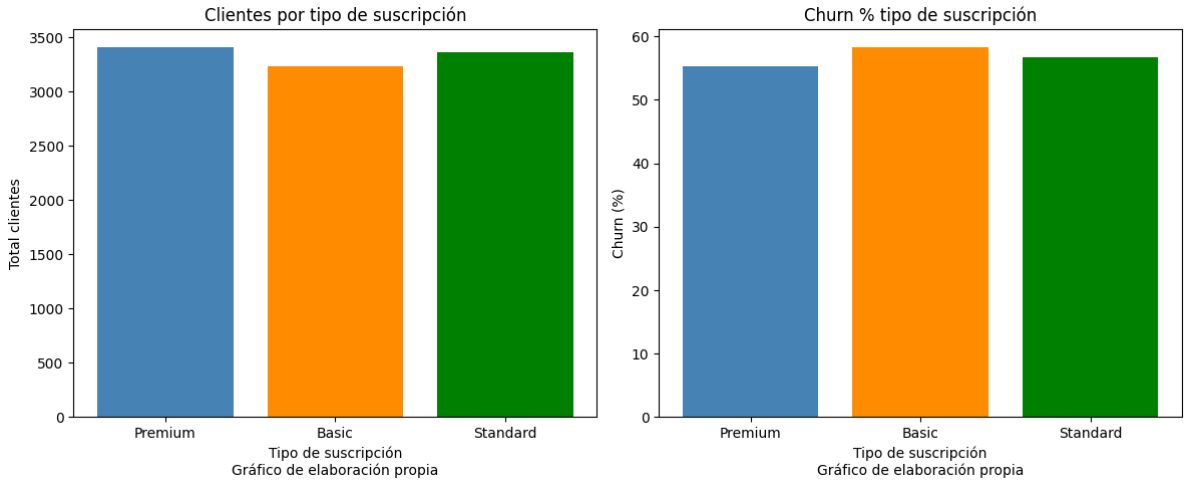
III. Análisis exploratorio con PySpark

Para empezar con el análisis exploratorio lo primero de todo es acceder a Google Colab, donde prepararemos el entorno para el análisis de los datos. Se nos indica que el tratamiento de datos se debe hacer en PySpark, esto es debido a que la gran cantidad de datos que tenemos no es fácilmente manejable por la libraría usual de Python, que viene siendo Pandas, por tanto, usamos el módulo de Spark en Python que nos permite este manejo de manera eficiente.

Para cargar los datos en el entorno debemos subir el archivo .csv a Google Drive. Una vez subidos vamos a seguir los siguientes pasos:

1. Instalamos el módulo de Spark en Python.
2. Importamos la sesión de Spark.
3. Importamos Google Drive como unidad física.
4. Cargamos los datos *customers_churn* en un Data Frame de Spark.
5. Resolvemos todas las peticiones que se nos preguntan.

Tras aplicar el código correspondiente nos queda el siguiente gráfico que nos muestra el número de clientes por cada tipo de suscripción y el % de churn por cada tipo:



Ahora vamos a hablar sobre las conclusiones profesionales que podemos obtener sobre los datos:

1. En la primera gráfica observamos los tres segmentos están equilibrados, lo que indica que no hay un tipo de suscripción que domine sobre otro. Esto sugiere que la empresa tiene una base de clientes diversificada, sin embargo, también podemos concluir que, aproximando, los clientes con suscripciones "normales" es el doble que las premium, lo que nos indica que cuesta fidelizar clientes premium.

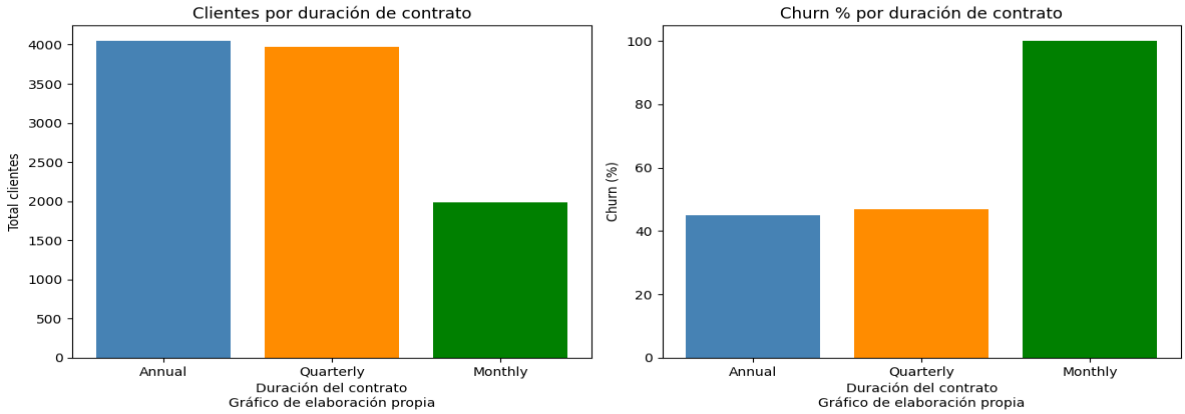
2. Los tres planes tienen un churn altísimo, por encima del 50%. Esto sugiere un problema estructural de compañía ya que el % de abandonos es muy alto en todas las suscripciones. Lo más preocupante es que el % de abandonos en la categoría premium es sumamente alto, lo que indica que el valor del producto no es bueno o no acaba de encajar con el público en general.

Subscription Type	total_clientes	churn_%
Premium	3406	55.28
Basic	3233	58.27
Standard	3361	56.68

La prioridad no debería ser mover clientes de suscripción Basic a Premium, sino entender por qué se van todos y conseguir la fidelización de los clientes a lo largo del tiempo, ya que como vemos numéricamente, el % de churn es superior al 50% en todos los tipos de suscripción.

Contract Length	total_clientes	churn_%
Annual	4046	45.06
Quarterly	3970	46.98
Monthly	1984	100.0

Por otro lado, para la duración del contrato, lo más preocupando son las bajas ocasionadas para los que solo están fidelizados por un mes yal y como vemos en el gráfico.



Nuevamente vamos a hablar sobre las implicaciones profesionales que tienen los resultados de los gráficos:

1. Los contratos *annual* y *quarterly* son mucho mayores, lo cual es de elogiar ya que han conseguido que el número de clientes que contratan en mayor longitud sea superior a los que contratan por corta duración. Sin embargo, el número de clientes que contratan mensualmente es alto y deberían de convertirse a *quarterly* y los de *quarterly* a *annual*.
2. Este gráfico es preocupante ya que indica nuevamente que el producto no es interesante ya que los que tienen posibilidad de salirse de la suscripción al mes lo aprovecha y se salen, lo que indica nuevamente que la fidelización no es la adecuada.

De estos gráficos se elogia el marketing inicial que logra convertir a clientes de larga duración y critica el producto ya que no es lo suficientemente bueno como para que no abandonen.

IV. Análisis descriptivo con PySpark

Para hacer un análisis descriptivo, donde calcularemos estadísticos, nos tenemos que asegurar de no tener datos faltantes y de no tratar con datos de tipo texto, por lo que en este caso, podemos observar que contamos con 10000 registros sin valores nulos ni missings:

```
+----------+---+------+------+---------------+-------------+-------------+-----------------+---------------+-----------+----------------+----------+
|CustomerID|Age|Gender|Tenure|Usage Frequency|Support Calls|Payment Delay|Subscription Type|Contract Length|Total Spend|Last Interaction|Churn_YesNo|
+----------+---+------+------+---------------+-------------+-------------+-----------------+---------------+-----------+----------------+----------+
|         0|  0|     0|     0|              0|            0|            0|                0|              0|          0|               0|         0|
+----------+---+------+------+---------------+-------------+-------------+-----------------+---------------+-----------+----------------+----------+
```

Dado que vamos a calcular estadísticos numéricos tenemos que excluir de dicho análisis las variables categóricas, es decir, podríamos excluir las variables *CustomerID*, *Gender*, *Subscription Type*, *Contract Lenght* y *Churn_ YesNo*. Sin embargo no nos interesa, por lo tanto, aplicaremos una transformación de los datos categóricos (salvo de *CustomerID*) para pasarlos a tipo numérico y poder contar con ellos más adelante, quedándonos el data frame como se muestra a continuación:

CustomerID	Age	Gender	Tenure	Usage Freq.	Support Calls	Payment Delay	Subscr. Type	Contract Length
314921.0	36.0	Male	10.0	14.0	1.0	20.0	Standard	Annual
401716.0	40.0	Male	20.0	23.0	4.0	6.0	Standard	Quarterly
99832.0	36.0	Female	52.0	23.0	1.0	0.0	Standard	Quarterly
168747.0	65.0	Male	55.0	3.0	10.0	14.0	Basic	Quarterly
126369.0	36.0	Male	49.0	1.0	1.0	23.0	Standard	Annual

Total Spend	Last Interact.	Churn YesNo	Gender _idx	Subscr. Type_idx	Contract Length_idx	Churn Labeled	features
736.02	27.0	No	0.0	1.0	0.0	1.0	[36.0,10.0,14.0,1...
897.3	29.0	No	0.0	1.0	1.0	1.0	[40.0,20.0,23.0,4...
697.0	29.0	Yes	1.0	1.0	1.0	0.0	[36.0,52.0,23.0,1...
130.0	6.0	Yes	0.0	2.0	1.0	0.0	[65.0,55.0,3.0,10...
136.0	18.0	Yes	0.0	1.0	0.0	0.0	[36.0,49.0,1.0,1....

Tras hacer el análisis estadístico obtenemos:

feature	mean	stddev
Age	39.2613	12.4925
Tenure	30.9536	17.1379
Usage Frequency	15.7726	8.6314
Support Calls	3.5932	3.0797
Payment Delay	13.0305	8.2619
Total Spend	633.3173	240.4718
Last Interaction	14.4916	8.6211
Gender_idx	0.4333	0.4956
Subscription Type_idx	0.9827	0.8147
Contract Length_idx	0.7938	0.7487
Churn_YesNo_Labeled	0.4328	0.4955

Vamos a hacer un análisis en profundidad del significado de estos estadísticos:

1. ***Age*:** La edad media es de 39.26 años con una desviación estándar de 12.49. Esto significa que los consumidores se distribuyen entre los 18 y 65 años según el mínimo y el máximo. La dispersión es relativamente baja lo que nos indica que los clientes son adultos, lo que nos sugiere o bien que el producto está orientado a adultos. La distribución de los datos podría ajustarse a una t-student, que es similar a una normal, pero con el punto medio un poco desviado.
2. ***Tenure*:** La media es de 30.95 meses con un máximo de 60 y una desviación de 17.14. El rango completo es de 1 a 60, por lo que está bien representado, indicando heterogeneidad en la base de clientes, que se corresponde con recién incorporados y clientes de largo plazo. Tenemos una desviación relativamente elevada relativa a la media lo que sugiere una alta variabilidad en la fidelización. Podríamos afirmar a priori que los datos se corresponden con una distribución normal (tras normalizar datos).
3. ***Usage Frequency*:** La media es de 15.77 sobre un máximo de 30, con desviación típica de 8.63. La distribución parece simétrica alrededor de la media ya que el punto medio es 15.50, lo que podría indicar una distribución uniforme o aproximadamente normal (tras normalizar los datos). El mínimo es 1, lo que nos indica que no existen cuentas inactivas.
4. ***Support Calls*:** Tenemos una media de 3.59 llamadas con un mínimo de 0 y máximo de 10. La desviación es de 3.08, lo que es alta respecto a la media, lo que indica que existen clientes con alta demanda de soporte. Esta variable nos indica que el producto tiene problemas o que es difícil de usar, lo cual nos puede dar una

idea de la variable churn y merece especial atención a la hora del paso de aprendizaje (variable a incluir en el modelo).

5. ***Payment Delay*:** La media es de 13.03 días con una desviación de 8.62 con un rango de 0 a 30. El hecho de que la media esté cerca del punto medio que es 15 y la desviación sea considerable sugiere que hay una variabilidad no despreciable en el comportamiento del pago. Los valores cercanos a 0 representan clientes puntuales, mientras que valores próximos a 30 son señales claras de riesgo de churn. Esta es otra variable que deberemos tener en cuenta a la hora del modelo de predicción.
6. ***Total Spend*:** Es la variable con mayor varianza y una media de 633.3. Tenemos un rango de 100 a 1000. El coeficiente de variación indica dispersión alta y la amplitud del rango sugiere diferencias notables en los planes o en el tiempo de permanencia.
7. ***Last Interaction*:** La media es de 14.49 días con una desviación de 8.62, y un rango de 1 a 30. La media está cerca al punto medio del rango y la desviación estándar es elevada, lo que indica una distribución amplia. Esto significa que hay clientes con valores altos de 20 días sin interacción lo que representa un segmento en riesgo de abandono.
8. **Gender_idx:** La media es de 0.43 con una desviación de 0.50. Al ser una variable binaria indexada (0 o 1), la media representa la proporción de una de las categorías, en este caso indica que aproximadamente el 43% de los clientes pertenecen a una categoría y el 57% a la otra. La desviación cercana a 0.50 es característica de variables binarias y confirma que la distribución está relativamente equilibrada entre ambos géneros.
9. **Subscription Type_idx:** Con una media de 0.98 y desviación de 0.81, esta variable tiene tres categorías indexadas (0, 1, 2). La media cercana a 1 indica que los valores se distribuyen de forma relativamente homogénea entre los tres tipos de suscripción. La desviación de 0.81 refleja la variabilidad esperada en una variable con más de dos categorías.

10. **Contract Length_idx:** La media es de 0.79 con una desviación de 0.75, también con tres categorías indexadas. La media por debajo de 1 sugiere que la categoría 0 (la más frecuente según el criterio de StringIndexer, que ordena por frecuencia) predomina ligeramente. Podría ser relevante en el modelo ya que el tipo de contrato está directamente relacionado con la permanencia y el riesgo de churn.

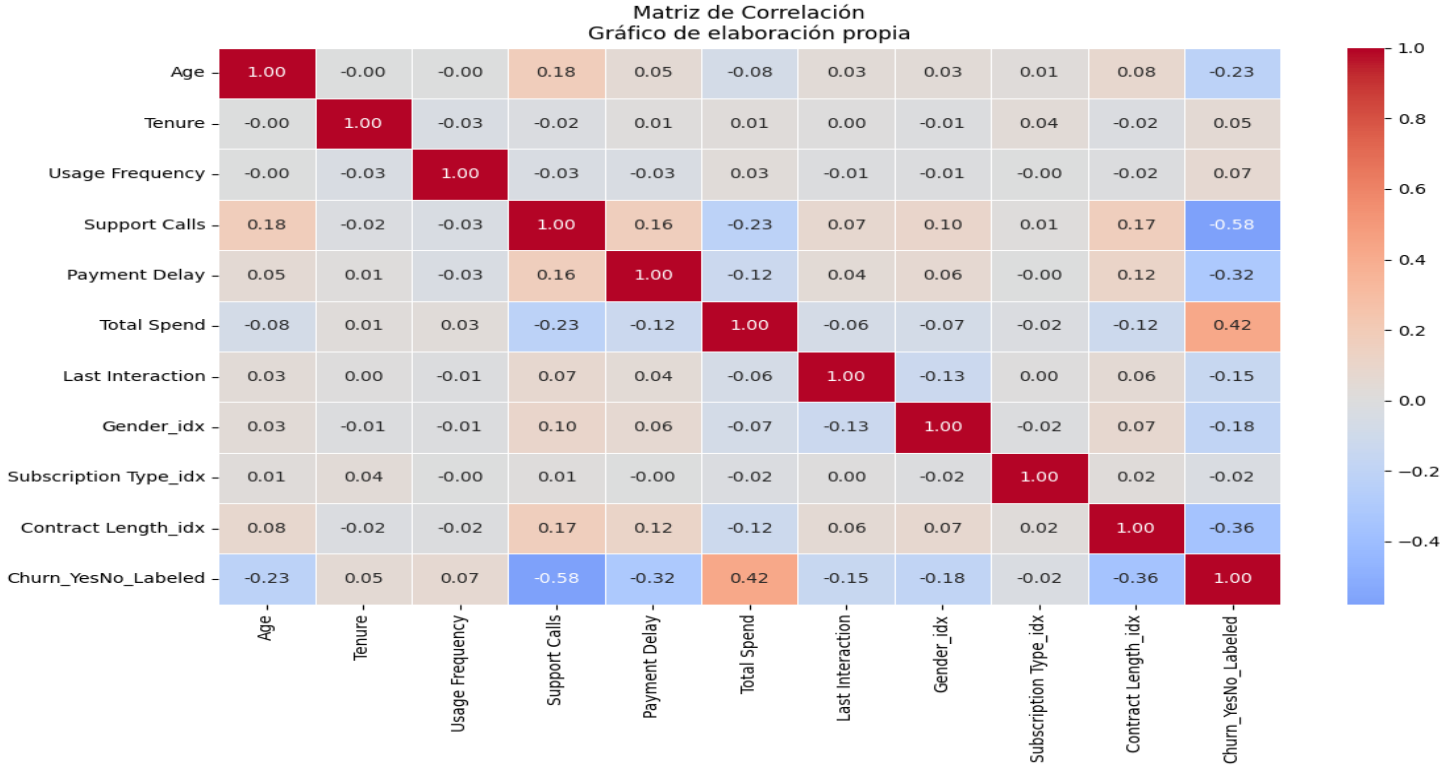
11. **Churn_YesNo_Labeled:** La media es de 0.43 con una desviación de 0.50, lo que nos indica que aproximadamente el 43% de los clientes han abandonado el servicio. Al ser nuestra variable objetivo, este valor es especialmente relevante ya que nos indica un dataset relativamente equilibrado, lo que es favorable para el entrenamiento del modelo y reduce el riesgo de sesgo hacia la clase mayoritaria.

V. Análisis de correlación

Para hacer un análisis de correlación debemos hacer uso del nueva data frame que construimos donde ya convertimos los datos de tipo texto a numéricos. Podemos observar la matriz de correlación numérica:

	Age	Tenure	Usage Frequency	Support Calls	Payment Delay	Total Spend	Last Interaction	Gender_idx	Subscription Type_idx	Contract Length_idx	Churn_YesNo_Labeled
Age	1.000000	-0.000693	-0.004411	0.175940	0.053811	-0.076583	0.033162	0.034406	0.014163	0.083979	-0.226358
Tenure	-0.000693	1.000000	-0.031740	-0.018698	0.007875	0.013821	0.002084	-0.005193	0.035615	-0.020832	0.053986
Usage Frequency	-0.004411	-0.031740	1.000000	-0.032477	-0.033654	0.029837	-0.010357	-0.013086	-0.003305	-0.015196	0.066370
Support Calls	0.175940	-0.018698	-0.032477	1.000000	0.164219	-0.225403	0.073694	0.096899	0.010509	0.172423	-0.578483
Payment Delay	0.053811	0.007875	-0.033654	0.164219	1.000000	-0.122547	0.044035	0.063189	-0.004424	0.115537	-0.317328
Total Spend	-0.076583	0.013821	0.029837	-0.225403	-0.122547	1.000000	-0.062719	-0.068477	-0.020887	-0.120416	0.423405
Last Interaction	0.033162	0.002084	-0.010357	0.073694	0.044035	-0.062719	1.000000	-0.130931	0.003504	0.055528	-0.150066
Gender_idx	0.034406	-0.005193	-0.013086	0.096899	0.063189	-0.068477	-0.130931	1.000000	-0.016112	0.072366	-0.184639
Subscription Type_idx	0.014163	0.035615	-0.003305	0.010509	-0.004424	-0.020887	0.003504	-0.016112	1.000000	0.023338	-0.024560
Contract Length_idx	0.083979	-0.020832	-0.015196	0.172423	0.115537	-0.120416	0.055528	0.072366	0.023338	1.000000	-0.358711
Churn_YesNo_Labeled	-0.226358	0.053986	0.066370	-0.578483	-0.317328	0.423405	-0.150066	-0.184639	-0.024560	-0.358711	1.000000

Como podemos observar, diferenciar cuales tienen la mayor correlación con la variable objetivo es bastante difícil con tantos datos. Por tanto pintamos la matriz de correlación con un mapa de calor:



El análisis de la matriz de correlación revela que la variable *Churn_ YesNo* tiene las correlaciones más altas del conjunto de datos. La correlación negativa más fuerte se da con la variable *Support Calls* con un valor de -0.58, lo que significa que, a mayor número de llamadas para obtener soporte, existe una mayor probabilidad de abandono del servicio, lo que nos indica una experiencia insatisfactoria por parte del cliente. Esto es un predictor clave de la variable *Churn_ YesNo*.

Las siguientes más altas son *Contract Length* con un valor -0.36 y *Payment Delay* con un valor de -0.32, donde los contratos más largos actúan como un factor que retiene a los clientes y los retrasos en el pago como señal de riesgo de abandono del servicio.

Por último, con una correlación positiva tenemos la variable *Total Spend* con un valor de 0.42, que nos muestra que los clientes que más gastan tienen mayor tendencia a dejar el servicio, lo cual puede indicar una percepción de precio elevado respecto al valor percibido.

El resto de las variables presentan correlaciones débiles entre sí y por tanto una buena independencia entre predictores. Destaca que las variables *Age*, *Tenure, Usage Frequency* o *Subscription Type* tienen correlaciones muy cercanas a 0 con respecto a la variable *Churn_ YesNo*, lo que indica que no son factores que determinen el abandono por sí solos.

El modelo predictivo que realizaremos debería priorizar las variables *Support Calls*, *Contract Length*, *Payment Delay* y *Total Spend* como las variables con mayor poder explicativo sobre la variable objetivo que es *Churn_ YesNo*.

VI. Selección del modelo predictivo

Tras todo el análisis que hemos realizado anteriormente, el modelo que vamos a elegir es el Random Forest. El motivo es el siguiente:

- Planteamos un problema de la predicción del abandono de los clientes, es decir, la variable *Churn_ YesNo*.

  El modelo Random Forest es el adecuado porque el comportamiento de los clientes suele depender de múltiples variables como el tipo de suscripción, la duración del contrato, la frecuencia del uso del producto, el historial de pagos o interacciones con soporte. Todas estas características cuyas relaciones con la decisión de abandonar no suelen ser lineales lo que dificultaría el uso de modelos como la recta de regresión lineal básica. Dentro del Machine Learning, el Random Forest combina múltiples árboles de decisión entrenados sobre diferentes subconjuntos de datos y variables, lo que permite capturar patrones complejos y reducir el riesgo de sobreajuste típico de un único árbol, por tanto, el modelo tiene una alta capacidad predictiva incluso cuando los datos contienen ruido o interacciones entre variables difíciles de modelar explícitamente. Dicho lo anterior, llegamos a la conclusión de que es una herramienta eficaz para identificar con anticipación qué clientes presentan mayor probabilidad de abandonar el servicio y así permitir a la empresa implementar estrategias de retención basadas en datos.

Para resolver este apartado usaremos dos formas. La primera forma es con la librería *Sklearn* y la segunda con *MLlib* de PySpark. El procedimiento es el siguiente:

1. Cargar las librerías necesarias.
2. Creamos el array de features con las variables que predeciremos *Churn_ YesNo*.
3. Dividimos los datos en train y test.
4. Creamos el grid de parámetros, entrenamos el modelo y guardamos el que mejores resultados nos da.
5. Calculamos las métricas y las pintamos.

	Accuracy_train	Precision_train	Recall_train	F1_train	Accuracy_test	Precision_test	Recall_test	F1_test
Random Forest	1.0	1.0	1.0	1.0	0.994	0.994011	0.994	0.994002

6. Calculamos la importancia en el modelo de cada variable.

```
Var:
  Support Calls                  0.3216
  Total Spend                    0.2098
  Contract Length_idx            0.1492
  Age                            0.1300
  Payment Delay                  0.1223
  Last Interaction               0.0341
  Gender_idx                     0.0279
  Tenure                         0.0026
  Usage Frequency                0.0017
  Subscription Type_idx          0.0007
```

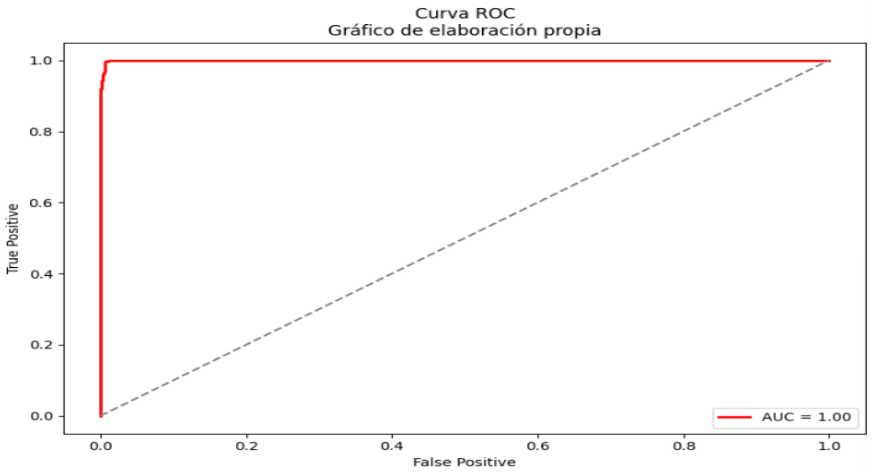
7. Pintamos la matriz de confusión y la curva *ROC*.

```
 Matriz de confusión para el Test
+---------------+----------+-----+
|Churn_YesNo_idx|prediction|count|
+---------------+----------+-----+
|            0.0|       0.0| 1157|
|            0.0|       1.0|   24|
|            1.0|       1.0|  815|
+---------------+----------+-----+
```

   Se muestra el rendimiento del modelo de predicción de sobre el conjunto de test. El modelo clasificó correctamente a 1.157 clientes que no se fueron verdaderos negativos, clase 0 predicha como 0 y a 815 clientes que sí se fueron verdaderos positivos, clase 1 predicha como 1. El único error que cometió fue clasificar 24 clientes dándose de baja cuando en realidad no era el caso (falsos positivos), y llama la atención que no aparece ningún caso de falso negativo (clientes que se fueron pero el modelo predijo que no), lo que sugiere que el modelo es especialmente bueno detectando el churn real.

Tal y como comentamos en el análisis de correlación, *Subscription_Type* no influye mucho en nuestra predicción y podríamos prescindir de esa variable. Lo mismo sucede con las variables *Tenure y Usage_Frequency*. La variable que más contribuye a nuestro modelo es *Support_Calls* lo cual tiene sentido ya que eso indica que el producto es complicado de usar o tiene múltiples fallos, sucesos que no agradan al usuario e influye directamente en el abandono o cese del servicio.

Tenemos la curva *ROC* que nos indica cuan bien ajusta los datos al modelo planteado:



Como podemos observar, la curva nos indica que la predicción es casi perfecta. Podríamos pensar que existe sobreajuste, sin embargo, si observamos las métricas del modelo observamos que:

	MSE_train	RMSE_train	MAE_train	R2_train	Adj_R2_train	MSE_test	RMSE_test	MAE_test	R2_test	Adj_test
Random Forest	0.0	0.0	0.0	1.0	1.0	0.006	0.07746	0.006	0.975561	0.975438

El error en el entrenamiento es 0 y en test, el error es menor a 0.1. Por otro lado, la métrica $R^2_{ajustado}$ = 1 en train y $R^2_{ajustado}$ = 0.97 en los datos de test, lo que nos indica que no existe sobreajuste ya que ambas métricas son muy similares en train y en test. Al observar estas métricas concluimos que no es necesario verificar otros modelos de predicción ya que este modelo nos da unos resultados que difícilmente se podrían mejorar y que nos da toda la información necesaria.

VII. Explicación de la toma del algoritmo

Vamos a dar la visión general del problema que hemos tratado y la conclusión:

El problema de negocio a resolver es la predicción del abandono de clientes, en nuestro caso, la variable *Churn_ YesNo* en una empresa de servicios en los que te puedes suscribir. Contamos con un dataset de 10.000 registros con variables como el tipo de suscripción, la duración del contrato, la frecuencia de uso, el historial de pagos y las llamadas al soporte.

El objetivo es anticipar qué clientes tienen mayor probabilidad de cancelar el servicio e identificar los factores clave que determinan esa decisión. La importancia del problema viene de los propios datos que nos muestran que los tres tipos de suscripción presentan tasas de abandono superiores al 50%, y en los contratos mensuales el abandono alcanza casi el 100%.

El análisis de correlación revela que las variables con mayor poder predictivo son *Support Calls* con un valor -0,58, que señala dificultades en el uso del producto o fallos técnicos irresolubles por el propio usuario. La variable *Total Spend* con un valor de 0,42, que indica que el precio no concuerda con el valor del producto actual. La variable *Contract Length* con un valor de -0,36, donde los contratos largos retienen mejor al cliente y *Payment Delay* con un valor de -0,32, donde los retrasos en el pago funcionan como señal temprana de riesgo de abandono.

Predecir el abandono con antelación permite a la empresa actuar de forma preventiva sobre los clientes en riesgo, optimizar la inversión en estrategias de fidelización y detectar problemas estructurales del producto antes de que se traduzcan en pérdida masiva de clientes. El modelo Random Forest desarrollado en el trabajo, con un AUC de 0,99 y un R^2 ajustado de 0,97 en los datos de test, demuestra que es posible alcanzar una capacidad predictiva casi perfecta con los datos disponibles, confirmando el alto valor de este análisis como herramienta de apoyo a la toma de decisiones empresariales.

En definitiva, el problema es estratégico, es decir, la empresa necesita comprender por qué se van sus clientes y tener la capacidad de anticiparlo con tiempo suficiente para reaccionar. La prioridad no debe ser convertir clientes básicos en premium, sino resolver las causas raíz del abandono, mejorar la experiencia del producto y diseñar incentivos que migren contratos de corta duración hacia compromisos anuales que garanticen una mayor fidelización.

VIII. Conclusión

El análisis demuestra que el abandono de clientes responde a una combinación de factores relacionados con la experiencia de usuario, siendo las llamadas al soporte, el gasto total, los retrasos en el pago y la duración del contrato. El modelo Random Forest alcanza un coeficiente AUC de 0,99 y un R^2 ajustado de 0,97 en test, confirmando que es posible predecir el churn con precisión casi perfecta sin sobreajuste. Esto convierte al modelo en una herramienta estratégica de alto valor, ya que permite identificar con antelación a los clientes en riesgo y actuar sobre las causas raíz del abandono.

Ya tenemos las causas del abandono identificadas y el camino a la meta final trazado, por tanto solo quedaría aplicar una estrategia que nos permita paliar los problemas existentes, permitiéndonos fidelizar a los clientes de manera efectiva y ajustar el precio al valor real del producto actual.