BIG DATA

PROYECTO FINAL

Josué Juan Hormiga Benítez



Tokio.

Resumen

En este TFM se trata el análisis exploratorio, limpieza de datos, completitud de los datos, predicción de modelos de machine learning (ML) y veracidad o fiabilidad del modelo para extraer conclusiones que nos ayudarán a obtener información procesable, optimizar los procesos de toma de decisiones e identificar patrones que de otra manera permanecerían ocultos entre los grandes volúmenes de información proporcionada.

Tokio.

Índice

1. Clasificación de datos mediante la plantilla.
2. Consultas con Cassandra.
3. Análisis exploratorio con PySpark.
4. Análisis descriptivo con PySpark.
5. Análisis de correlación.
6. Selección de algoritmo predictivo.
7. Explicación de la toma del algoritmo.
8. Conclusión.

Clasificación de datos

Para entender el contexto general del problema tendremos que analizar los datos según su estructura. Para ello los clasificamos de la siguiente manera:

Nombre del campo	Tipo de dato
CustomerID	Texto
Age	Flotante
Gender	Texto
Tenure	Flotante
Usage Frequency	Flotante
Support Calls	Flotante
Payment Delay	Flotante
Subscription Type	Texto
Contract Length	Texto
Total Spend	Flotante
Last Interaction	Flotante
Churn_YesNo	Texto

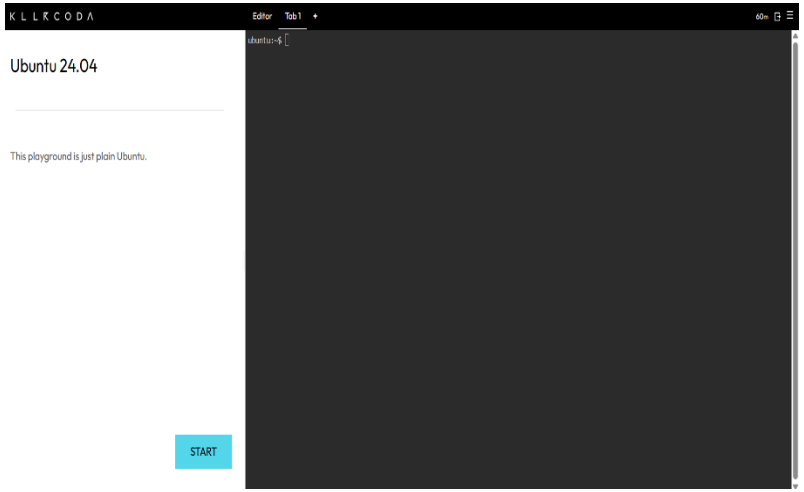
Clasificación de datos

Los datos que tenemos representan lo siguiente:

1. *CustomerID*: Es un identificativo interno que nos permite localizar a un cliente sin posibles conflictos.
2. *Age*: Nos indica la edad del cliente.
3. *Gender*: Nos indica el género del cliente.
4. *Tenure*: antigüedad del cliente
5. *Usage Frequency*: frecuencia de uso del teléfono
6. *Support Calls*: es el número de llamadas al servicio de atención al cliente
7. *Payment Delay*: es el número de retrasos en el pago
8. *Subscription Type*: nos indica el tipo de tarifa
9. *Contract Length*: es la duración del contrato
10. *Total Spend*: es el gasto total
11. *Last Interaction*: días desde la última interacción con el cliente
12. *Churn_YesNo*: Nos indica si el cliente ha dado de baja el servicio (en tal caso será -> Yes).

Consultas con Cassandra

Cassandra nos permitirá responder a ciertas preguntas. Para ello tenemos que entrar a la interfaz



Una vez dentro preparamos el Docker y la imagen de Cassandra para poder empezar a trabajar.

Consultas con Cassandra

Para empezar a trabajar con Cassandra debemos aplicar los siguientes comandos:

1. ***Descargamos la imagen de Cassandra***: docker pull cassandra:3.11
2. ***Creamos la red***: docker network create cassandra
3. ***Iniciamos el contenedor***: docker run –rm -d –name cassandra –hostname cassandra –network cassandra cassandra:3.11
4. ***Conectamos con cqlsh***: docker run –rm -it –network cassandra nuvo/Docker-cqlsh cqlsh cassandra 9042 –cqlversion='3.4.4'

Responderemos a las siguientes preguntas:

A. Recuperar todos los registros de la tarifa Basic: "Subscription Type" = "Basic". ¿cuántos clientes hay?

Para resolverlo usaremos la instrucción:

```
SELECT COUNT(*) FROM customers WHERE subscription_type = 'Basic';
```

B. Recuperar todos los registros de la tarifa Basic: "Subscription Type" = "Basic", y con contrato anual: "Contract Length" = "Annual"¿cuántos clientes hay?

Para resolverlo usaremos la instrucción:

```
SELECT COUNT(*) FROM customers WHERE subscription_type = 'Basic' AND contract_length = 'Annual' ALLOW FILTERING;
```

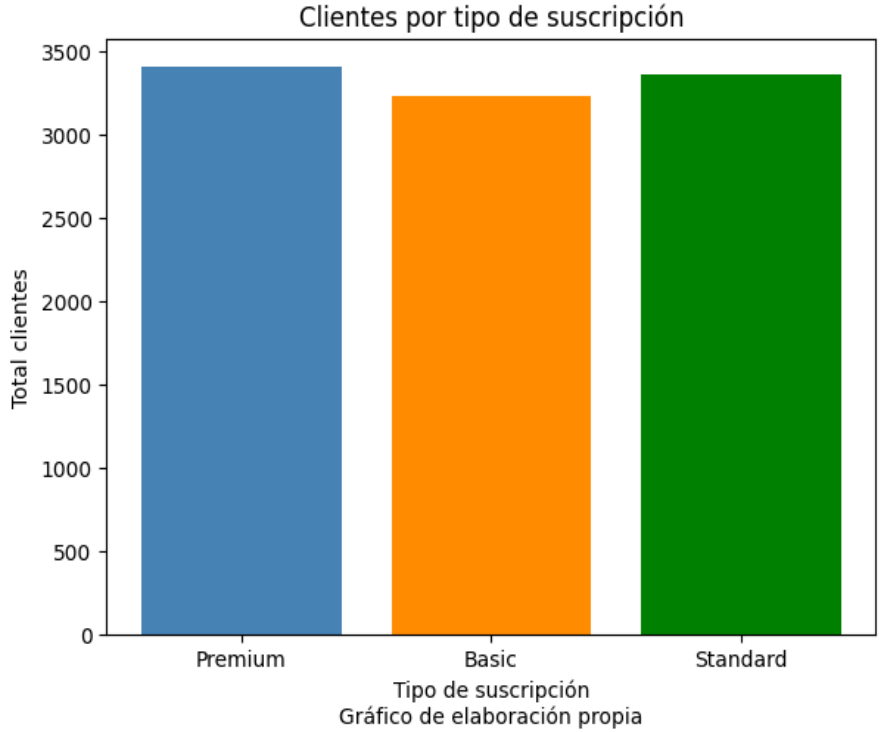
Resultados obtenidos:

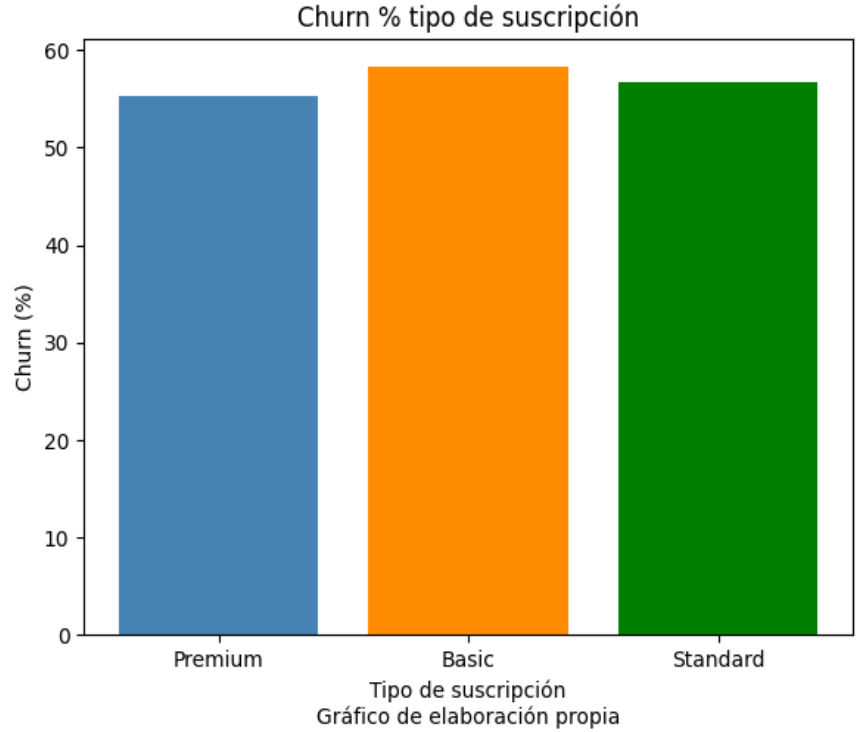
1. Clientes con suscripción Basic: **3.233 clientes**
2. Clientes con suscripción Basic y contrato anual: **1.250 clientes**

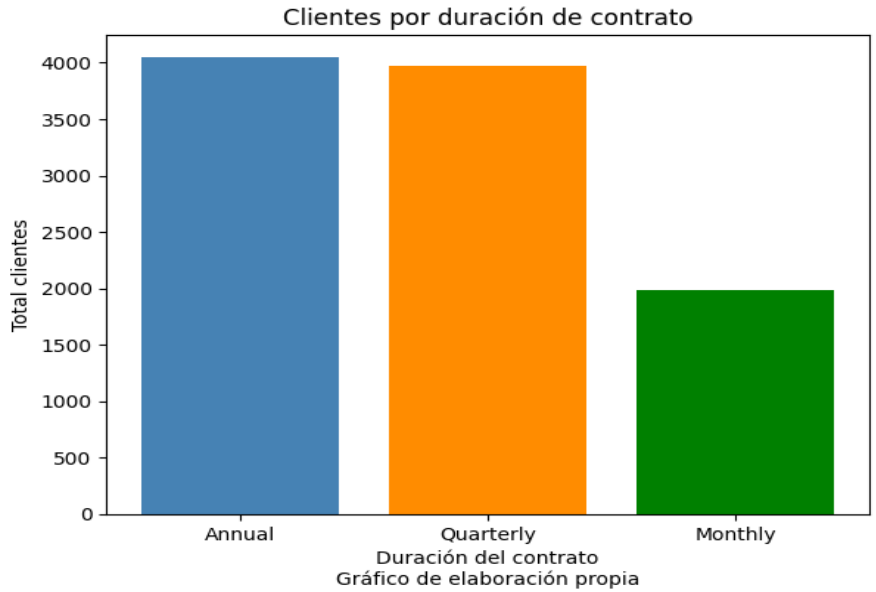
Tokio.

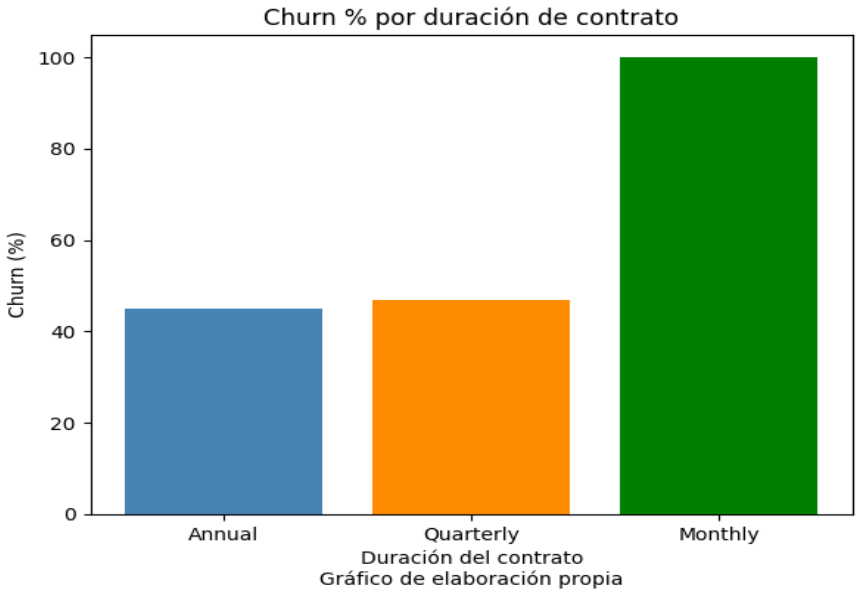
Análisis exploratorio con PySpark

En esta sección mostraremos cuántos clientes y qué churn hay en cada tipo de tarifa, mostraremos esa información en uno o dos charts y haremos lo mismo para la duración del contrato. Para hacer el análisis exploratorio con PySpark accedemos a Google Colab e instalamos los módulos necesarios. Tras tener todo listo obtenemos las gráficas que mostramos a continuación.


Clientes por tipo de suscripción
Total clientes
0
500
1000
1500
2000
2500
3000
3500
Premium
Basic
Standard
Tipo de suscripción
Gráfico de elaboración propia


Churn % tipo de suscripción
Churn (%)
0
10
20
30
40
50
60
Premium
Basic
Standard
Tipo de suscripción
Gráfico de elaboración propia


Clientes por duración de contrato
Total clientes
0
500
1000
1500
2000
2500
3000
3500
4000
Annual
Quarterly
Monthly
Duración del contrato
Gráfico de elaboración propia


Churn % por duración de contrato
Churn (%)
0
20
40
60
80
100
Annual
Quarterly
Monthly
Duración del contrato
Gráfico de elaboración propia

Proyecto Final Big Data

1. En la primera gráfica observamos los tres segmentos están equilibrados, lo que indica que no hay un tipo de suscripción que domine sobre otro. Esto sugiere que la empresa tiene una base de clientes diversificada, sin embargo, también podemos concluir que, aproximando, los clientes con suscripciones “normales” es el doble que las premium, lo que nos indica que cuesta fidelizar clientes premium.

2. Los tres planes tienen un churn altísimo, por encima del 50%. Esto sugiere un problema estructural de compañía ya que el % de abandonos es muy alto en todas las suscripciones. Lo más preocupante es que el % de abandonos en la categoría premium es sumamente alto, lo que indica que el valor del producto no es bueno o no acaba de encajar con el público en general.

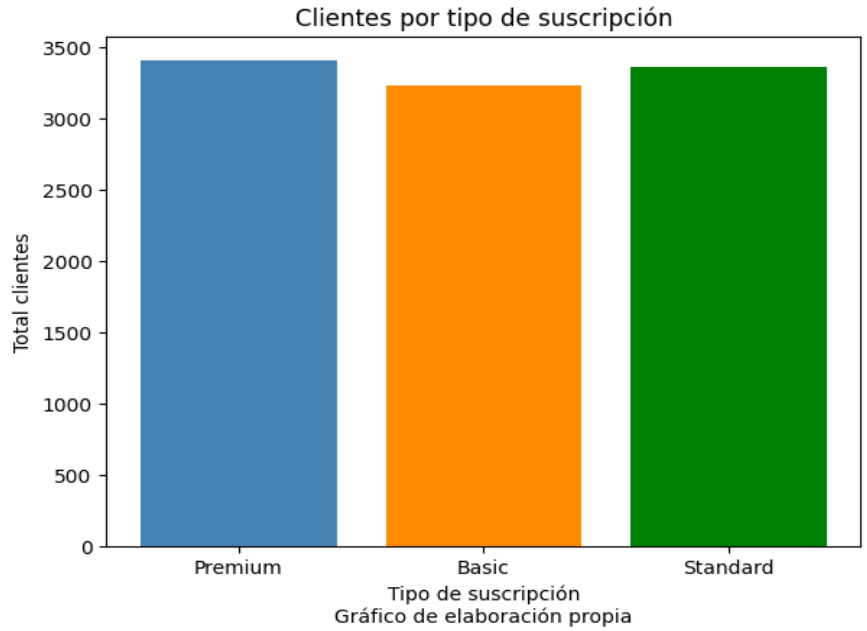


Gráfico de elaboración propia

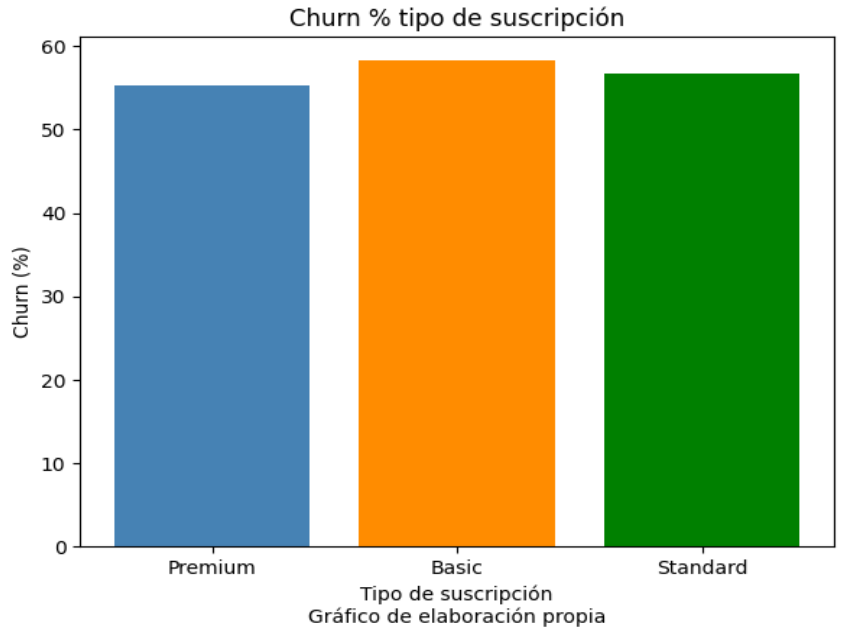
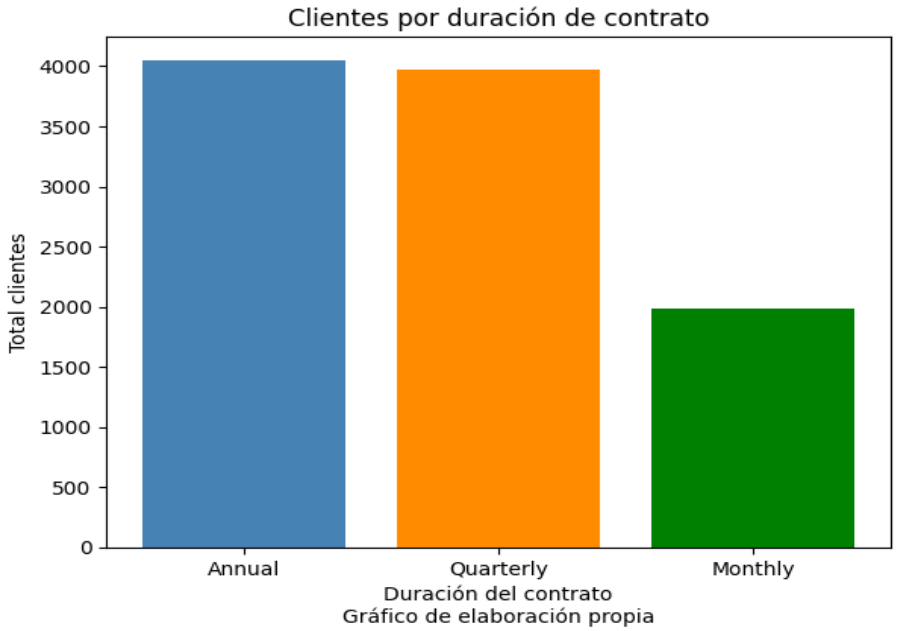
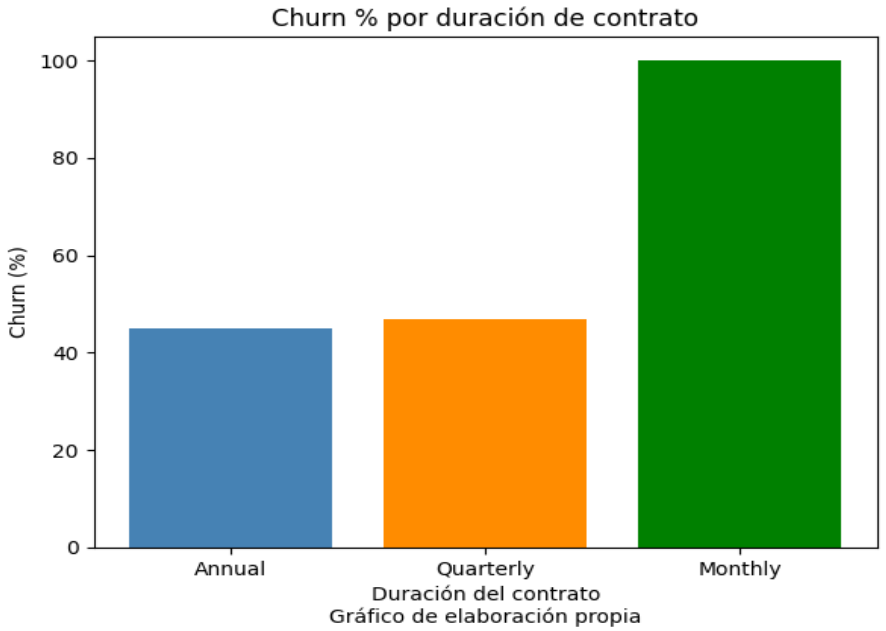


Gráfico de elaboración propia

1. Los contratos *annual* y *quarterly* son mucho mayores, lo cual es de elogiar ya que han conseguido que el número de clientes que contratan en mayor longitud sea superior a los que contratan por corta duración. Sin embargo, el número de clientes que contratan mensualmente es alto y deberían de convertirse a *quarterly* y los de *quarterly* a *annual*.

2. Este gráfico es preocupante ya que indica nuevamente que el producto no es interesante ya que los que tienen posibilidad de salirse de la suscripción al mes lo aprovecha y se salen, lo que indica nuevamente que la fidelización no es la adecuada.





Tokio.

Análisis descriptivo con PySpark

Para hacer un análisis descriptivo donde calcularemos estadísticos, nos tenemos que asegurar de no tener datos faltantes y de no tratar con datos de tipo texto, por lo que, en este caso podemos observar que contamos con 10000 registros sin valores nulos ni missings:

CustomerID	Age	Gender	Tenure	Usage Frequency	Support Calls	Payment Delay	Subscription Type	Contract Length	Total Spend	Last Interaction	Churn_YesNo
0	0	0	0	0	0	0	0	0	0	0	0

Proyecto Final Big Data

Para poder incluir en nuestro análisis todas las variables menos CustomerID vamos a hacer una transformación a tipo numérico, donde nos queda la siguiente tabla:

CustomerID	Age	Gender	Tenure	Usage Freq.	Support Calls	Payment Delay	Subscr. Type	Contract Length
314921.0	36.0	Male	10.0	14.0	1.0	20.0	Standard	Annual
401716.0	40.0	Male	20.0	23.0	4.0	6.0	Standard	Quarterly
99832.0	36.0	Female	52.0	23.0	1.0	0.0	Standard	Quarterly
168747.0	65.0	Male	55.0	3.0	10.0	14.0	Basic	Quarterly
126369.0	36.0	Male	49.0	1.0	1.0	23.0	Standard	Annual

Total Spend	Last Interact.	Churn YesNo	Gender _idx	Subscr. Type_idx	Contract Length_idx	Churn _YesNo_idx	features
736.02	27.0	No	0.0	1.0	0.0	1.0	[36.0,10.0,14.0,1...
897.3	29.0	No	0.0	1.0	1.0	1.0	[40.0,20.0,23.0,4...
697.0	29.0	Yes	1.0	1.0	1.0	0.0	[36.0,52.0,23.0,1...
130.0	6.0	Yes	0.0	2.0	1.0	0.0	[65.0,55.0,3.0,10...
136.0	18.0	Yes	0.0	1.0	0.0	0.0	[36.0,49.0,1.0,1....

Tokio.

De esta manera, obtenemos los estadísticos que queríamos:

feature	mean	stddev
Age	39.2613	12.4925
Tenure	30.9536	17.1379
Usage Frequency	15.7726	8.6314
Support Calls	3.5932	3.0797
Payment Delay	13.0305	8.2619
Total Spend	633.3173	240.4718
Last Interaction	14.4916	8.6211
Gender_idx	0.4333	0.4956
Subscription Type_idx	0.9827	0.8147
Contract Length_idx	0.7938	0.7487
Churn_YesNo_Labeled	0.4328	0.4955

Age: La edad media es de 39.26 años con una desviación estándar de 12.49. Esto significa que los consumidores se distribuyen entre los 18 y 65 años según el mínimo y el máximo.

Tenure: La media es de 30.95 meses con un máximo de 60 y una desviación de 17.14. El rango completo es de 1 a 60, por lo que está bien representado, indicando heterogeneidad en la base de clientes, que se corresponde con recién incorporados y clientes de largo plazo.

Usage Frequency: La media es de 15.77 sobre un máximo de 30, con desviación típica de 8.63. La distribución parece simétrica alrededor de la media ya que el punto medio es 15.50, lo que podría indicar una distribución uniforme o aproximadamente normal (tras normalizar los datos). El mínimo es 1, lo que nos indica que no existen cuentas inactivas.

Support Calls: Tenemos una media de 3.59 llamadas con un mínimo de 0 y máximo de 10. La desviación es de 3.08, lo que es alta respecto a la media, lo que indica que existen clientes con alta demanda de soporte.

Payment Delay: La media es de 13.03 días con una desviación de 8.62 con un rango de 0 a 30. El hecho de que la media esté cerca del punto medio que es 15 y la desviación sea considerable sugiere que hay una variabilidad no despreciable en el comportamiento del pago.

Total Spend: Es la variable con mayor varianza y una media de 633.3.

Last Interaction: La media es de 14.49 días con una desviación de 8.62, y un rango de 1 a 30. La media está cerca al punto medio del rango y la desviación estándar es elevada, lo que indica una distribución amplia. Esto significa que hay clientes con valores altos de 20 días sin interacción lo que representa un segmento en riesgo de abandono.

Tokio.

Gender_idx: La media es de 0.43 con una desviación de 0.50. Al ser una variable binaria indexada (0 o 1), la media representa la proporción de una de las categorías, en este caso indica que aproximadamente el 43% de los clientes pertenecen a una categoría y el 57% a la otra.

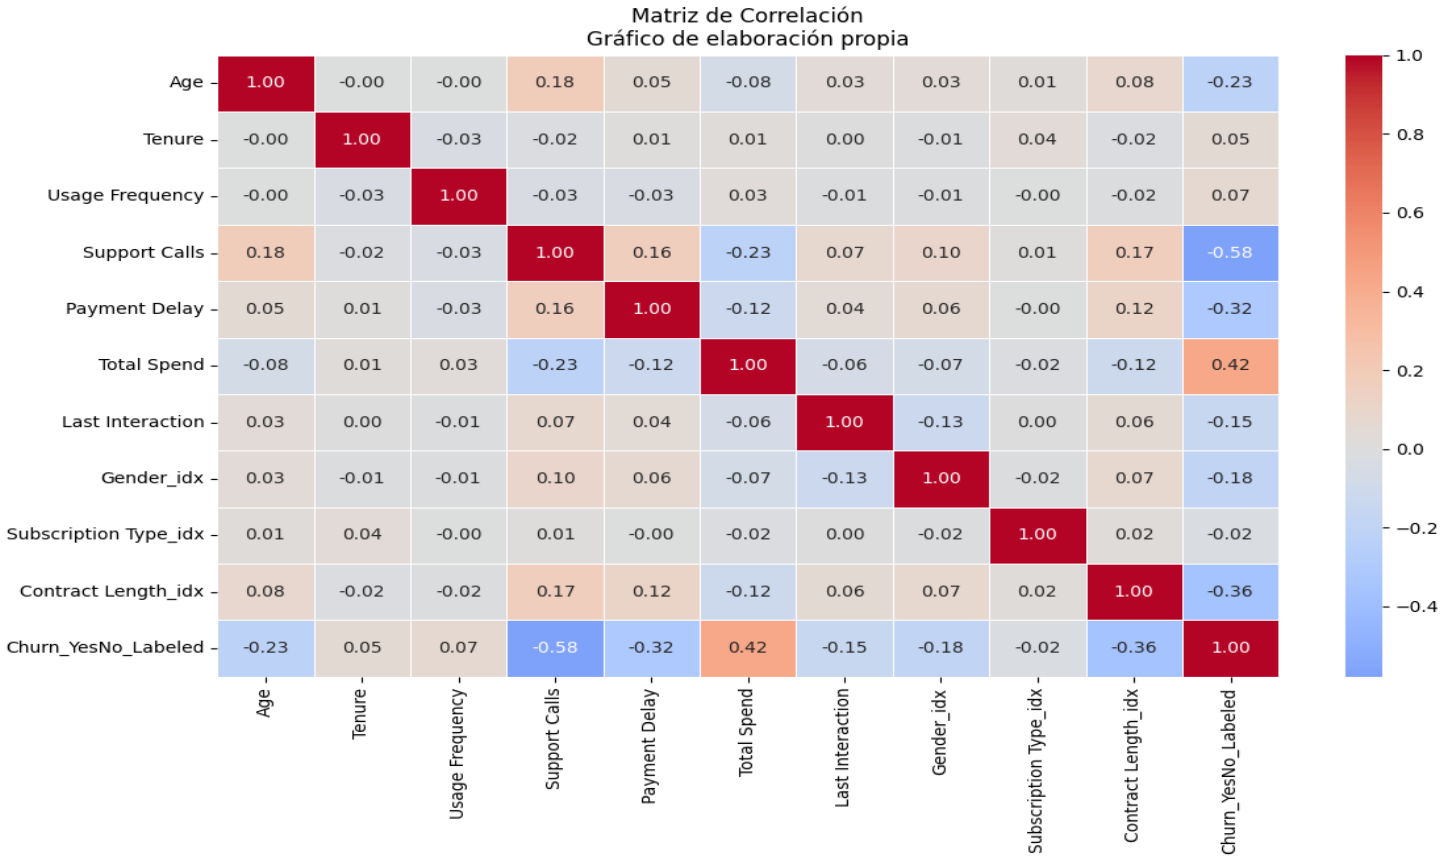
Subscription Type_idx: Con una media de 0.98 y desviación de 0.81, esta variable tiene tres categorías indexadas (0, 1, 2). La media cercana a 1 indica que los valores se distribuyen de forma relativamente homogénea entre los tres tipos de suscripción.

Contract Length_idx: La media es de 0.79 con una desviación de 0.75, también con tres categorías indexadas. La media por debajo de 1 sugiere que la categoría 0 (la más frecuente según el criterio de StringIndexer, que ordena por frecuencia) predomina ligeramente.

Churn_YesNo_Labeled: La media es de 0.43 con una desviación de 0.50, lo que nos indica que aproximadamente el 43% de los clientes han abandonado el servicio. Al ser nuestra variable objetivo, este valor es especialmente relevante ya que nos indica un dataset relativamente equilibrado, lo que es favorable para el entrenamiento del modelo y reduce el riesgo de sesgo hacia la clase mayoritaria.

Análisis de correlación

Para hacer un análisis de correlación debemos hacer uso del nuevo data frame que construimos donde ya convertimos los datos de tipo texto a numéricos. Podemos observar la matriz de correlación numérica representada en un mapa de calor:



El análisis de la matriz de correlación revela que la variable *Churn_ YesNo* tiene las correlaciones más altas del conjunto de datos. La correlación negativa más fuerte se da con la variable *Support Calls* con un valor de -0.58, lo que significa que, a mayor número de llamadas para obtener soporte, existe una mayor probabilidad de abandono del servicio, lo que nos indica una experiencia insatisfactoria por parte del cliente. Esto es un predictor clave de la variable *Churn_ YesNo*.

Las siguientes más altas son *Contract Length* con un valor -0.36 y *Payment Delay* con un valor de -0.32, donde los contratos más largos actúan como un factor que retiene a los clientes y los retrasos en el pago como señal de riesgo de abandono del servicio.

Por último, con una correlación positiva tenemos la variable *Total Spend* con un valor de 0.42, que nos muestra que los clientes que más gastan tienen mayor tendencia a dejar el servicio, lo cual puede indicar una percepción de precio elevado respecto al valor percibido.

El resto de las variables presentan correlaciones débiles entre sí y por tanto una buena independencia entre predictores.

Selección del modelo predictivo

Tras todo el análisis que hemos realizado anteriormente, el modelo que vamos a elegir es el Random Forest. El motivo es el siguiente:

Planteamos un problema de la predicción del abandono de los clientes, es decir, la variable *Churn_ YesNo*.

El modelo Random Forest es el adecuado porque el comportamiento de los clientes suele depender de múltiples variables como el tipo de suscripción, la duración del contrato, la frecuencia del uso del producto, el historial de pagos o interacciones con soporte. Todas estas características cuyas relaciones con la decisión de abandonar no suelen ser lineales lo que dificultaría el uso de modelos como la recta de regresión lineal básica. Dentro del Machine Learning, el Random Forest combina múltiples árboles de decisión entrenados sobre diferentes subconjuntos de datos y variables, lo que permite capturar patrones complejos y reducir el riesgo de sobreajuste típico de un único árbol, por tanto, el modelo tiene una alta capacidad predictiva incluso cuando los datos contienen ruido o interacciones entre variables difíciles de modelar explícitamente. Dicho lo anterior, llegamos a la conclusión de que es una herramienta eficaz para identificar con anticipación qué clientes presentan mayor probabilidad de abandonar el servicio y así permitir a la empresa implementar estrategias de retención basadas en datos.

Las métricas que obtenemos del modelo son:

	Accuracy_train	Precision_train	Recall_train	F1_train	Accuracy_test	Precision_test	Recall_test	F1_test
Random Forest	1.0	1.0	1.0	1.0	0.994	0.994011	0.994	0.994002

La importancia de cada variable es:

```
Var:
  Support Calls                0.3216
  Total Spend                  0.2098
  Contract Length_idx          0.1492
  Age                          0.1300
  Payment Delay                0.1223
  Last Interaction             0.0341
  Gender_idx                   0.0279
  Tenure                       0.0026
  Usage Frequency              0.0017
  Subscription Type_idx        0.0007
```

Tokio.

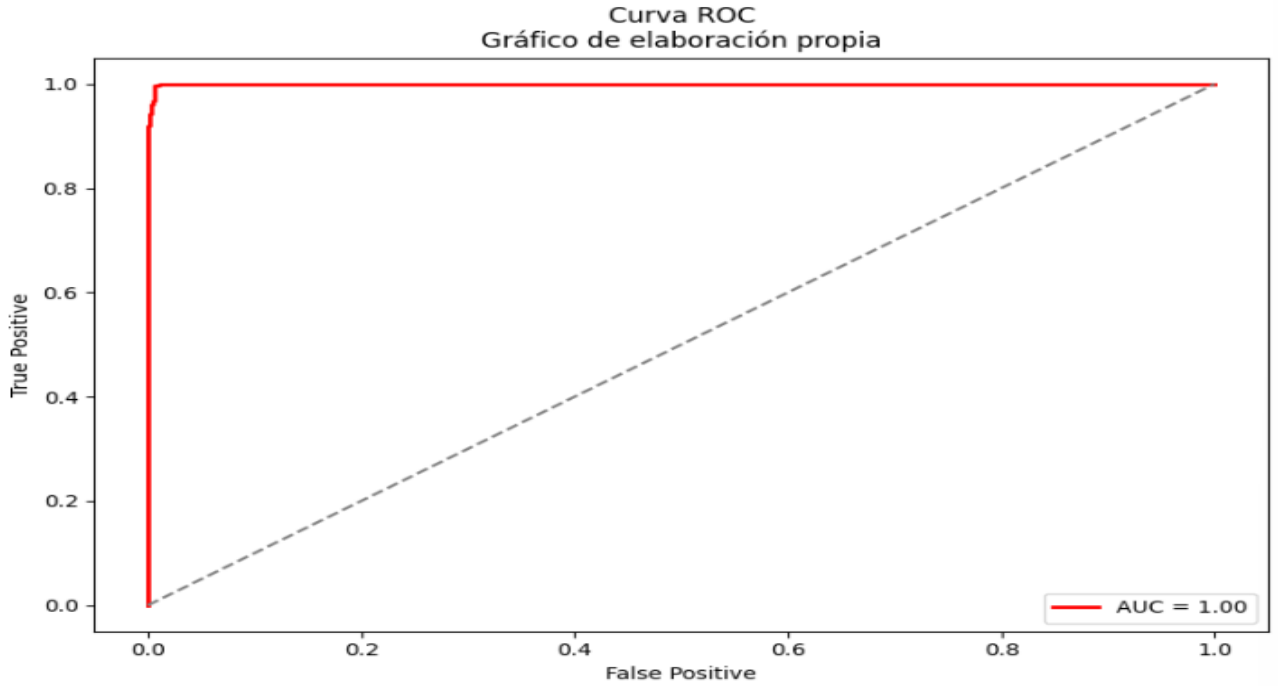
La matriz de confusión es:

Matriz de confusión para el Test

Churn_YesNo_idx	prediction	count
0.0	0.0	1157
0.0	1.0	24
1.0	1.0	815

Se muestra el rendimiento del modelo de predicción de sobre el conjunto de test. El modelo clasificó correctamente a 1.157 clientes que no se fueron verdaderos negativos, clase 0 predicha como 0 y a 815 clientes que sí se fueron verdaderos positivos, clase 1 predicha como 1. El único error que cometió fue clasificar 24 clientes dándose de baja cuando en realidad no era el caso (falsos positivos), y llama la atención que no aparece ningún caso de falso negativo (clientes que se fueron, pero el modelo predijo que no), lo que sugiere que el modelo es especialmente bueno detectando el churn real.

Tenemos la curva ROC:



Como podemos ver en la curva, los datos ajustan bastante bien.

Predecir el abandono con antelación permite a la empresa actuar de forma preventiva sobre los clientes en riesgo, optimizar la inversión en estrategias de fidelización y detectar problemas estructurales del producto antes de que se traduzcan en pérdida masiva de clientes. El modelo Random Forest desarrollado en el trabajo, con un AUC de 0,99 y un R^2 ajustado de 0,97 en los datos de test, demuestra que es posible alcanzar una capacidad predictiva casi perfecta con los datos disponibles, confirmando el alto valor de este análisis como herramienta de apoyo a la toma de decisiones empresariales.

En definitiva, el problema es estratégico, es decir, la empresa necesita comprender por qué se van sus clientes y tener la capacidad de anticiparlo con tiempo suficiente para reaccionar. La prioridad no debe ser convertir clientes básicos en premium, sino resolver las causas raíz del abandono, mejorar la experiencia del producto y diseñar incentivos que migren contratos de corta duración hacia compromisos anuales que garanticen una mayor fidelización.